

# BÁO CÁO TỔNG HỢP ASSIGNMENT 01 & ASSIGNMENT 02

## INTELLIGENT SYSTEM DEVELOPMENT — HỆ THỐNG THÔNG MINH

**Giảng viên hướng dẫn:** TS. Đinh Quế Trần (quetd@ptit.edu.vn)

**Học viện:** Học viện Công nghệ Bưu chính Viễn thông (PTIT)

**Sinh viên thực hiện:** Đinh Hải Triều

**Mã sinh viên:** B23DCCN843 | **Nhóm:** 06

**File nộp quy chuẩn:** `A01\_06\_trieu.b23dccn843.PDF`

---



## MỤC LỤC BÁO CÁO (TABLE OF CONTENTS)

### 📌 PHẦN I: KHUNG KHÁI NIỆM & LÝ THUYẾT NỀN TẢNG (SLIDE 01)

1. Kết nối Khung Khái niệm Môn học (Ma trận Ánh xạ Khái niệm ↔ Thực hành)
2. Ý tưởng Cốt lõi về Biểu diễn Dữ liệu (Data Representation & Vector Space)
3. So sánh Traditional Machine Learning vs Deep Learning trên Dữ liệu Bảng
4. Tầm quan trọng của Feature Scaling (StandardScaler & Tránh Data Leakage)
5. Định nghĩa Các Độ đo Đánh giá (Classification Metrics & Regression Metrics)

### 🔗 PHẦN II: BÀI 1 — HỆ CHẨN ĐOÁN BỆNH TIỂU ĐƯỜNG (ASSIGNMENT 01 - PART 1)

1. Định nghĩa Hệ thống & Mô tả Dữ liệu Pima Diabetes (8 Đặc trưng Y tế)
2. Sơ đồ Kiến trúc Hệ thống Bài 1 & Phân tích Chi tiết 6 Khối Tương tác
3. Biểu đồ Khám phá Dữ liệu (EDA) & Giải thích Cận kề Chuyên sâu
  - Biểu đồ Phân phối 8 Đặc trưng Y tế (KDE Distributions & Skewness)
  - Ma trận Tương quan Pearson (Correlation Heatmap & Multicollinearity)
4. Kết quả Huấn luyện & Đánh giá 5 Mô hình Classification
  - Bảng So sánh 5 Mô hình ML & Baseline (Accuracy, Precision, Recall, F1)
  - Ma trận Nhầm lẫn (Confusion Matrices) & Phân tích Ý nghĩa Lâm sàng (FN vs FP)
5. Thí nghiệm Siêu tham số  $k$  trong k-NN (Bias-Variance Tradeoff & Overfitting)
6. Kết quả Demo Dự đoán 3 Bệnh nhân Thực tế (High-risk, Low-risk, Mid-risk)

### 🏠 PHẦN III: BÀI 2 — HỆ DỰ ĐOÁN GIÁ NHÀ VIỆT NAM 2024 (ASSIGNMENT 02 / PART 2)

1. Định nghĩa Hệ thống & Mô tả Dữ liệu Vietnam Housing 2024 (6 Thuộc tính BĐS)
2. Sơ đồ Kiến trúc Hệ thống Bài 2 & Phân tích Chi tiết 6 Khối Tương tác
3. 3 Biểu đồ Phân phối Bắt buộc & Giải thích Cận kề Chuyên sâu
  - Biểu đồ 1: Phân phối Giá nhà gốc vs Biến đổi Log Transform ( $\log(1 + y)$ )
  - Biểu đồ 2: Phân tích Diện tích & Boxplot Giá nhà theo Tỉnh/Thành
  - Biểu đồ 3: Ma trận Tương quan Đặc trưng BĐS (Correlation Heatmap)
4. Kết quả Huấn luyện & Đánh giá 5 Mô hình Hồi quy (5 Độ đo Đánh giá)
  - Bảng Đánh giá 5 Mô hình Regressors & Baseline (MAE, MSE, RMSE,  $R^2$ , MAPE)
  - Biểu đồ So sánh Hệ số  $R^2$  Score giữa 5 Mô hình Hồi quy
5. Kết quả Demo Ước tính Giá 3 BĐS Thực tế & Khoảng tin cậy  $\pm 15\%$

### 💻 PHẦN IV: TRIỂN KHAI WEB / MOBILE (IN-BROWSER ML INFERENCE)

1. Thuật toán In-Browser ML Engine bằng Pure JavaScript (< 2ms, No Server)
2. Tính năng Lời khuyên Y tế & Đề xuất Cá nhân hóa Tự động
3. Repositories GitHub & Deploy Vercel 1-Click

### 🎓 PHẦN V: REFLECTION VÀ KẾT LUẬN

1. Trả lời 8 Câu hỏi Reflection Chuyên sâu

## 2. Tổng kết Bài làm & Hướng Phát triển

---

# PHẦN I: KHUNG KHÁI NIỆM & LÝ THUYẾT NỀN TẢNG (SLIDE 01)

## 1. Kết nối Khung Khái niệm Môn học

Trong môn học *Intelligent System Development*, tiến trình phát triển một hệ thống thông minh tuân theo 6 giai đoạn:

Intelligence → Intelligent System → Representation → Learning → Decision → Action

Triết lý triển khai thực tiễn:

Understand → Represent → Implement → Experiment → Apply

**Ma trận Ánh xạ Khái niệm ↔ Thực hành:**

| Khái niệm Slide 01      | Hiện thực hóa trong Bài 1 & Bài 2                     | Bảng chứng thực nghiệm trong Báo cáo                                    |
|-------------------------|-------------------------------------------------------|-------------------------------------------------------------------------|
| Intelligence            | Khả năng suy luận & dự đoán trường hợp mới            | Chẩn đoán tiểu đường & Dự đoán giá BĐS                                  |
| Intelligent System      | Tích hợp: Data + Representation + Model + Application | Sơ đồ hệ thống & Single Page Web App                                    |
| External Info           | Dữ liệu thô từ thực tế                                | Pima Diabetes & Vietnam Housing 2024                                    |
| Internal Representation | Vector đặc trưng $x \in \mathbb{R}^d$                 | Feature table & Feature matrix $X \in \mathbb{R}^{N \times d}$          |
| Learning                | Thuật toán học từ dữ liệu mẫu                         | Quá trình fit 5 mô hình ML                                              |
| Decision                | Kết quả dự đoán $\hat{y}$                             | Nhãn binary $\hat{y} \in \{0, 1\}$ / Giá nhà $\hat{y} \in \mathbb{R}^+$ |
| Action / Application    | Web App / Mobile Responsive hỗ trợ người dùng         | Giao diện Web 100% In-browser ML                                        |

---

## 2. Ý tưởng Cốt lõi về Biểu diễn Dữ liệu (Data Representation)

Mô hình Machine Learning không tiếp nhận thế giới thực một cách trực tiếp, mà thông qua **Không gian Biểu diễn Vector**:

$$x_i = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{id} \end{bmatrix} \in \mathbb{R}^d, \quad X = \begin{bmatrix} x_1^T \\ x_2^T \\ \vdots \\ x_N^T \end{bmatrix} \in \mathbb{R}^{N \times d}$$

**Nguyên lý toán học:** "Representation determines what information is available to learning." — Biểu diễn đặc trưng quyết định chất lượng học của mô hình.

### 3. So sánh Traditional Machine Learning vs Deep Learning

#### - Traditional Machine Learning:

$$\text{Raw Data} \xrightarrow{\text{Human Feature Engineering}} x \in \mathbb{R}^d \xrightarrow{\text{Traditional ML}} \hat{y}$$

- Phù hợp tuyệt đối với dữ liệu bảng (Tabular Data) vừa và nhỏ ( $N < 100,000$ ). - Tốc độ huấn luyện siêu nhanh, có khả năng giải thích cao, không đòi hỏi phần cứng GPU.

#### - Deep Learning:

$$\text{Raw Data} \xrightarrow{\text{Neural Network (End-to-End Representation Learning)}} \hat{y}$$

- Phù hợp dữ liệu phi cấu trúc (Ảnh, Tiếng nói, Văn bản). Dễ bị Overfitting trên dữ liệu bảng nhỏ.

### 4. Tầm quan trọng của Feature Scaling

Các thuật toán dựa trên khoảng cách (k-NN, SVM) hoặc tối ưu bằng Gradient (Logistic Regression) đòi hỏi đặc trưng phải cùng thang đo. **StandardScaler** biến đổi:

$$x'_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}$$

- Lưu ý *Data Leakage*: Chỉ 'fit' trên tập **Train**, sau đó 'transform' cho tập **Test** và dữ liệu thực tế.

### 5. Định nghĩa Các Độ đo Đánh giá (Evaluation Metrics)

#### A. Phân loại (Classification):

- **Accuracy:**  $\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN}$  - **Precision:**  $\text{Precision} = \frac{TP}{TP+FP}$  - **Recall:**  $\text{Recall} = \frac{TP}{TP+FN}$  - **F1-Score:**  $\text{F1} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$

#### B. Hồi quy (Regression):

- **MAE:**  $\text{MAE} = \frac{1}{N} \sum |y_i - \hat{y}_i|$  - **RMSE:**  $\text{RMSE} = \sqrt{\frac{1}{N} \sum (y_i - \hat{y}_i)^2}$  - **R<sup>2</sup> Score:**  $R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$  - **MAPE:**  $\text{MAPE} = \frac{100\%}{N} \sum \left| \frac{y_i - \hat{y}_i}{y_i} \right|$

## PHẦN II: BÀI 1 — HỆ CHẨN ĐOÁN BỆNH TIỂU ĐƯỜNG (ASSIGNMENT 01 - PART 1)

### 1. Định nghĩa Hệ thống & Mô tả Dữ liệu


- **Bài toán:** Binary Classification chẩn đoán bệnh tiểu đường Type 2 ( $Outcome \in \{0, 1\}$ ). - **Dataset:** Pima Indians Diabetes Database (768 bệnh nhân nữ  $\geq 21$  tuổi, 8 đặc trưng y tế).

**Bảng Biểu diễn 8 Đặc trưng Y tế ( $x \in \mathbb{R}^8$ ):**

| Đặc trưng                  | Tên Tiếng Việt              | Đơn vị            | Miền giá trị  |
|----------------------------|-----------------------------|-------------------|---------------|
| `Pregnancies`              | Số lần mang thai            | Lần               | 0 – 17        |
| `Glucose`                  | Nồng độ Glucose huyết tương | mg/dL             | 44 – 199      |
| `BloodPressure`            | Huyết áp tâm trương         | mmHg              | 24 – 122      |
| `SkinThickness`            | Độ dày nếp da tam đầu       | mm                | 7 – 99        |
| `Insulin`                  | Nồng độ Insulin huyết thanh | mu U/ml           | 14 – 846      |
| `BMI`                      | Chỉ số khối cơ thể          | kg/m <sup>2</sup> | 18.2 – 67.1   |
| `DiabetesPedigreeFunction` | Tiền sử gia đình (DPF)      | Chỉ số            | 0.078 – 2.420 |
| `Age`                      | Tuổi bệnh nhân              | Năm               | 21 – 81       |

---

### 2. Sơ đồ Kiến trúc Hệ thống Bài 1



Sơ đồ hệ thống 1

#### ✦ GIẢI THÍCH CHI TIẾT SƠ ĐỒ HỆ THỐNG BÀI 1:


1. **Môi trường (Environment):** Quần thể bệnh nhân thực tế mang các chỉ số sinh hóa tiềm ẩn nguy cơ tiểu đường. 2. **Đầu vào (Input):** Thu thập 8 thông số y tế đo đặc trực tiếp từ xét nghiệm máu và chỉ số cơ thể. 3. **Biểu diễn (Representation):** Chuyển đổi dữ liệu thô thành Vector toán học  $x = [x_1, x_2, \dots, x_8]^T \in \mathbb{R}^8$ . Đồng thời thực hiện Imputation (thay thế các giá trị 0 phi lý sinh lý ở Glucose/BMI bằng Median) và StandardScaler. 4. **Mô hình ML (Classifier):** Khối xử lý trung tâm (Random Forest / Decision Tree) chứa hàm suy luận  $f(x)$  đã được huấn luyện để phân tách không gian  $\mathbb{R}^8$ . 5. **Dự đoán (Decision):** Trả về nhãn nhị phân  $\hat{y} \in \{0, 1\}$  cùng xác suất

dự đoán  $P(Y = 1|x)$ . 6. **Ứng dụng (Application):** Tích hợp vào Web Application/Mobile để bác sĩ lâm sàng tra cứu và ra quyết định sàng lọc bệnh sớm.

---

### 3. Biểu đồ Khám phá Dữ liệu (EDA) & Giải thích Cận kề

#### Biểu đồ Phân phối 8 Đặc trưng Y tế




Phân phối 1

#### ✦ GIẢI THÍCH CẬN KỀ BIỂU ĐỒ PHÂN PHỐI 8 ĐẶC TRƯNG:

- **Glucose (Nồng độ Glucose huyết tương):** Đồ thị biểu diễn hai đường phân phối KDE rõ rệt. Nhóm không mắc bệnh (xanh) tập trung ở dải 80 – 110 mg/dL, trong khi nhóm mắc bệnh (đỏ) lệch hẳn về phía bên phải với đỉnh ở 140 – 160 mg/dL. Đây là đặc trưng có tính phân tách (Separability) cao nhất. - **BMI (Chỉ số khối cơ thể):** Nhóm bệnh nhân tiểu đường có trung vị BMI xấp xỉ 35.0 kg/m<sup>2</sup> (thuộc nhóm béo phì độ II), cao hơn đáng kể so với trung vị 30.0 kg/m<sup>2</sup> ở nhóm bình thường. Điều này phù hợp với y khoa khi béo phì là nguyên nhân hàng đầu gây kháng Insulin. - **Age (Tuổi):** Nhóm bệnh nhân tiểu đường có độ tuổi trung bình cao hơn (35 – 50 tuổi), phản ánh nguy cơ tích lũy theo thời gian. - **Pregnancies, Insulin, SkinThickness, BloodPressure:** đều có độ lệch phải (Right-skewed). Các giá trị 0 không hợp lệ ở Insulin và SkinThickness đã được xử lý làm sạch, loại bỏ hiện tượng méo mó dữ liệu.

---

**Ma trận Tương quan (Correlation Heatmap)**

Tương quan 1

**✦ GIẢI THÍCH CẶN KẾ MA TRẬN TƯƠNG QUAN:**

- **Tương quan với biến mục tiêu Outcome:** - `Glucose` có hệ số tương quan Pearson cao nhất ( $r = 0.49$ ), khẳng định mối quan hệ tuyến tính/phi tuyến mạnh mẽ nhất với nguy cơ mắc bệnh. - `BMI` xếp thứ hai ( $r = 0.31$ ), tiếp theo là `Age` ( $r = 0.24$ ) và `Pregnancies` ( $r = 0.22$ ). - **Tương quan giữa các đặc trưng đầu vào (Multicollinearity):** - Tương quan cao giữa `Age` và `Pregnancies` ( $r = 0.54$ ): Phụ nữ lớn tuổi hơn thường có số lần mang thai nhiều hơn. - Tương quan giữa `BMI` và `SkinThickness` ( $r = 0.39$ ): Cả hai đều phản ánh lượng mỡ thừa tích tụ trên cơ thể. - **Kết luận phân tích:** Do không có cặp đặc trưng nào có tương quan cực đại ( $r > 0.85$ ), cả 8 đặc trưng đều được giữ lại để đưa vào biểu diễn vector  $\mathbb{R}^8$  mà không bị đa cộng tuyến nghiêm trọng.

---

**4. Kết quả Huấn luyện & Đánh giá 5 Mô hình Classification**


Chia dữ liệu: **80% Train (614 mẫu)** và **20% Test (154 mẫu)** (Stratified Split).

Bảng So sánh 5 Mô hình ML:

| Mô hình                       | Accuracy | Precision | Recall | F1-Score | Đánh giá              |
|-------------------------------|----------|-----------|--------|----------|-----------------------|
| Baseline (Most Frequent)      | 64.94%   | 0.0000    | 0.0000 | 0.0000   | Mốc cơ sở             |
| Logistic Regression           | 70.78%   | 0.6000    | 0.5000 | 0.5455   | Tuyến tính            |
| k-NN ( $k = 7$ )              | 72.73%   | 0.6250    | 0.5556 | 0.5882   | Dựa trên khoảng cách  |
| Decision Tree ( $depth = 5$ ) | 75.97%   | 0.6393    | 0.7222 | 0.6783   | Recall cao nhất       |
| Random Forest ( $n = 100$ )   | 74.03%   | 0.6591    | 0.5370 | 0.5918   | Mô hình chính ổn định |
| SVM (RBF Kernel)              | 74.03%   | 0.6522    | 0.5556 | 0.6000   | Siêu phẳng phi tuyến  |

---

Ma trận Nhầm lẫn (Confusion Matrices) của 5 Mô hình



Confusion Matrices 1


📌 GIẢI THÍCH CẶN KẼ MA TRẬN NHẦM LẦN (CONFUSION MATRICES):

Trong bài toán y tế, giá trị của **False Negative (FN)** và **False Positive (FP)** có ý nghĩa lâm sàng rất khác nhau: - **False Negative (FN - Bỏ sót bệnh):** Bệnh nhân thực sự bị tiểu đường nhưng mô hình dự đoán là không bệnh. Đây là sai sót **rất nguy hiểm** vì người bệnh không được điều trị kịp thời. - **False Positive (FP - Cảnh báo giả):** Bệnh nhân không bệnh nhưng dự đoán có bệnh. Gây tốn chi phí xét nghiệm bổ sung nhưng an toàn hơn FN.

**Phân tích chi tiết ma trận 5 mô hình:** 1. **Decision Tree:** Đạt kết quả ấn tượng với  $FN = 15$  ca (thấp nhất trong 5 mô hình), giúp nâng **Recall lên 0.7222 (72.22%)**. Mô hình bắt được 39/54 ca bệnh trên tập test. 2. **Random Forest:** Đạt  $FP = 15$  ca (thấp hơn Decision Tree  $FP = 22$ ), đưa **Precision đạt 0.6591 (65.91%)**. Sự kết hợp ngẫu nhiên của 100 cây quyết định giúp mô hình chống vạt nhiễu (Variance reduction) rất tốt. 3. **Logistic Regression & k-NN:** Cho tỷ lệ  $FN = 27$  và 24 ca tương đối cao, cho thấy mô hình tuyến tính chưa bao quát hết được các ranh giới phi tuyến phức tạp trong dữ liệu y sinh.

---

## 5. Thí nghiệm Siêu tham số $k$ trong $k$ -NN



Hyperparameter 1

### ✦ GIẢI THÍCH CẶN KẾ ĐỒ THỊ SIÊU THAM SỐ $k$ :

- **Khi  $k = 1$  (Hiệu ứng Overfitting):** Ranh giới quyết định (Decision Boundary) bị chia nhỏ quá mức, mô hình khớp cả những điểm nhiễu (Noise) của tập Train. Trên tập Test, F1-Score chỉ đạt khoảng 0.48. - **Khi  $k$  tăng từ 2 đến 7:** Đồ thị Accuracy (xanh) và F1-Score (đỏ) đồng loạt đi lên. Mô hình mịn hóa ranh giới và mở rộng khả năng tổng quát hóa (Generalization). - **Vùng tối ưu ( $k = 7 \rightarrow 11$ ):** Đạt đỉnh hiệu năng với Accuracy  $\approx 72.7\%$  và F1-Score  $\approx 0.588$ . - **Khi  $k > 12$  (Hiệu ứng Underfitting):** Số lượng láng giềng quá lớn khiến các lớp đa số (Majority class - không bệnh) lấn át lớp yếu số (Minority class - có bệnh), dẫn đến Recall và F1-Score suy giảm liên tục.

---

## 6. Kết quả Demo Dự đoán 3 Bệnh nhân Thực tế

Mô hình **Random Forest** xuất file `model\_disease.pkl` và thử nghiệm: 1. **Bệnh nhân 1 (Nguy cơ cao):** Glucose=148, BMI=33.6, Age=50  $\rightarrow$  `CÓ NGUY CƠ TIỂU ĐƯỜNG` (Xác suất 65.4%) 2. **Bệnh nhân 2 (Nguy cơ thấp):** Glucose=85, BMI=26.6, Age=31  $\rightarrow$  `KHÔNG CÓ NGUY CƠ` (Xác suất 88.2%) 3. **Bệnh nhân 3 (Trung bình):** Glucose=120, BMI=28.5, Age=40  $\rightarrow$  `KHÔNG CÓ NGUY CƠ` (Xác suất 57.9%)

---

## PHẦN III: BÀI 2 — HỆ DỰ ĐOÁN GIÁ NHÀ VIỆT NAM 2024 (ASSIGNMENT 02 / PART 2)

### 1. Định nghĩa Hệ thống & Mô tả Dữ liệu

- **Bài toán:** Regression dự đoán giá nhà theo tỷ đồng ( $Price \in \mathbb{R}^+$ ). - **Dataset:** Vietnam Housing Dataset 2024 (2,000 mẫu bất động sản thực tế).

**Bảng Đặc trưng Đầu vào BĐS ( $x \in \mathbb{R}^6$ ):**

| Đặc trưng   | Ý nghĩa           | Mã hóa / Miền giá trị                                  |
|-------------|-------------------|--------------------------------------------------------|
| `Province`  | Tỉnh/Thành phố    | Label Encoded (Hà Nội=3, TP.HCM=7, Đà Nẵng=8, ...)     |
| `Area`      | Diện tích đất/nhà | 20.0 – 500.0 m <sup>2</sup>                            |
| `Bedrooms`  | Số phòng ngủ      | 1 – 5 phòng                                            |
| `Bathrooms` | Số phòng tắm/WC   | 1 – 5 phòng                                            |
| `Floors`    | Số tầng           | 1 – 5 tầng                                             |
| `HouseType` | Loại hình nhà ở   | Label Encoded (Biệt thự=0, Chung cư=1, Nhà phố=2, ...) |

---

2. Sơ đồ Kiến trúc Hệ thống Bài 2



Sơ đồ hệ thống 2


📌 **GIẢI THÍCH CHI TIẾT SƠ ĐỒ HỆ THỐNG BÀI 2:**

1. **Môi trường BĐS:** Thị trường giao dịch bất động sản biến động mạnh tại 10 Tỉnh/Thành phố trọng điểm Việt Nam. 2. **Thông tin đầu vào:** Các thuộc tính vật lý của ngôi nhà (Tỉnh thành, Diện tích, Số phòng, Loại nhà). 3. **Biểu diễn số:** Chuyển đổi thuộc tính định tính (`Province`, `HouseType`) bằng Label Encoding và chuẩn hóa bằng StandardScaler thành vector  $x \in \mathbb{R}^6$ . 4. **Mô hình Hồi quy (Regressor):** Thuật toán Gradient Boosting Regressor xây dựng chuỗi 80 cây quyết định hồi quy học từ sai số dư (Residuals). 5. **Dự đoán:** Trả về mức giá ước tính liên tục  $\hat{y} \in \mathbb{R}^+$  (đơn vị: tỷ đồng). 6. **Ứng dụng:** Hỗ trợ khách hàng, định giá viên ngân hàng và người mua nhà tra cứu giá thị trường tức thì.

---

### 3. 3 Biểu đồ Phân phối Bất buộc & Giải thích Cận kề

**Biểu đồ 1: Phân phối Giá nhà (Price & Log Transform)**




Biểu đồ 1 Giá nhà

#### 📌 GIẢI THÍCH CẬN KẾ BIỂU ĐỒ 1 (PHÂN PHỐI GIÁ NHÀ):

- **Biểu đồ 1a (Phân phối giá gốc):** Phân phối có độ lệch phải (Positive/Right-skewed) cực nặng. Đa số các căn nhà giao dịch ở mức 2.0 – 15.0 tỷ đồng, nhưng có một đuôi dài kéo rộng đến 150 – 200 tỷ đồng đại diện cho các căn biệt thự hạng sang. Nếu giữ nguyên biến mục tiêu này, các thuật toán hồi quy bình phương tối thiểu (OLS) sẽ bị kéo lệch nghiêm trọng bởi các giá trị ngoại lệ (Outliers). - **Biểu đồ 1b (Phân phối sau phép biến đổi Log):** Sử dụng hàm  $y' = \log(1 + y)$  đã nén đuôi dài bên phải và đưa phân phối về dạng chuông đối xứng chuẩn (Gaussian Distribution). Điều này thỏa mãn giả định về tính ổn định phương sai (Homoscedasticity) giúp mô hình đạt sai số thấp nhất.

**Biểu đồ 2: Diện tích & Giá nhà theo Tỉnh/Thành**



Biểu đồ 2 Diện tích


#### 📌 GIẢI THÍCH CẬN KẾ BIỂU ĐỒ 2 (DIỆN TÍCH & ĐỊA LÝ):

- **Biểu đồ 2a (Scatter Plot Area vs Price):** - Cho thấy mối quan hệ tương quan thuận đồng biến rất mạnh: Diện tích tăng thì tổng giá trị nhà tăng theo. - Phân màu theo `HouseType` chỉ ra phân tầng giá trị: Loại hình **Biệt thự** (vàng) nằm ở nhóm trên cùng với đơn giá trên m² cao nhất; loại hình **Chung cư** và **Nhà trọ** nằm ở nhóm dưới với

giá trị vừa phải. - **Biểu đồ 2b (Boxplot Giá nhà theo Tỉnh/Thành):** - **Hà Nội** và **TP.HCM** sở hữu giá trung vị (Median) và khoảng tứ phân vị (IQR) cao áp đảo toàn bộ các tỉnh thành khác (trung vị khoảng 25 – 35 tỷ đối với nhà đất). - Các tỉnh thành như **Đồng Nai, Cần Thơ, Hải Phòng** có mức giá trung bình dễ chịu hơn (5 – 12 tỷ), thể hiện sự phân hóa địa lý kinh tế rõ rệt trong biểu diễn dữ liệu.

---

**Biểu đồ 3: Ma trận Tương quan Đặc trưng BĐS (Correlation Heatmap)**



Biểu đồ 3 Tương quan

**📌 GIẢI THÍCH CẶN KẾ MA TRẬN TƯƠNG QUAN BĐS:**

- **`Area` (Diện tích):** Hệ số tương quan  $r = 0.58$  với biến **`Price`**. Đây là yếu tố quan trọng nhất quyết định quy mô giá trị ngôi nhà. - **`Province` (Tỉnh/Thành):** Hệ số tương quan  $r = 0.35$ , khẳng định yếu tố vị trí địa lý trong bất động sản ("Nhất vị trí, nhì diện tích"). - **`Bedrooms` & `Bathrooms`:** Tương quan  $r = 0.32$  và  $r = 0.30$  với giá nhà, đồng thời hai biến này có tương quan chéo với nhau ( $r = 0.62$ ), phản ánh thiết kế nhà ở thông thường (số phòng ngủ tăng thì số phòng tắm tăng theo).

---

4. Kết quả Huấn luyện & Đánh giá 5 Mô hình Hồi quy (5 Độ đo)


Chia dữ liệu: **80% Train (1,600 mẫu)** và **20% Test (400 mẫu)**.

**Bảng Đánh giá 5 Mô hình Regressors:**

| Mô hình            | MAE (tỷ) | MSE    | RMSE (tỷ) | $R^2$ Score | MAPE (%) | Đánh giá           |
|--------------------|----------|--------|-----------|-------------|----------|--------------------|
| Baseline (Mean)    | 12.9030  | 288.42 | 16.9830   | 0.0000      | 115.4%   | Cơ sở              |
| Linear Regression  | 7.9711   | 149.17 | 12.2137   | 0.5765      | 52.46%   | Tuyến tính         |
| SVR (RBF Kernel)   | 6.8227   | 113.37 | 10.6477   | 0.6781      | 35.30%   | Phi tuyến          |
| Decision Tree Reg. | 6.0943   | 96.18  | 9.8074    | 0.7269      | 32.02%   | Cây đơn            |
| Random Forest Reg. | 4.7090   | 58.59  | 7.6544    | 0.8337      | 24.30%   | Ensemble           |
| Gradient Boosting  | 4.0664   | 45.09  | 6.7154    | 0.8720      | 20.49%   | 🏆 Mô hình tốt nhất |

---

**Biểu đồ So sánh Hệ số  $R^2$  Score giữa 5 Mô hình Hồi quy**



So sánh Regressors

📌 **GIẢI THÍCH CẶN KẾ ĐỒ THỊ SO SÁNH 5 MÔ HÌNH HỒI QUY:**

- **Baseline Model ( $R^2 = 0.0000$ ):** Luôn dự đoán bằng giá trị trung bình của tập Train, cho sai số MAE rất lớn (12.90 tỷ). - **Linear Regression ( $R^2 = 0.5765$ ):** Mô hình tuyến tính chỉ giải thích được 57.65% biến thiên của giá nhà do không bắt được các tương tác phi tuyến giữa Tỉnh thành và Loại hình nhà. - **SVR & Decision Tree ( $R^2 = 0.6781$  và  $0.7269$ ):** Cải thiện rõ rệt nhờ khả năng phân chia ranh giới phi tuyến. - **Random Forest ( $R^2 = 0.8337$ ):** Kỹ thuật Bagging kết hợp 100 cây quyết định giảm mạnh variance, đưa sai số MAE xuống 4.71 tỷ. - **Gradient Boosting ( $R^2 = 0.8720$  - 🏆 Tốt nhất):** Thuật toán Boosting tối ưu hóa chuỗi các cây học

yếu (Weak learners) dựa trên Gradient của hàm mất mát. Mô hình giải thích được tới **87.20%** sự biến động của giá nhà, giảm MAE xuống chỉ còn **4.06 tỷ đồng** (giảm hơn **68%** sai số so với Baseline).

---

### 5. Kết quả Demo Ước tính Giá 3 BĐS Thực tế

Mô hình **Gradient Boosting** xuất file `model\_house\_price.pkl` và dự đoán: 1. **Nhà phố Hà Nội (80m<sup>2</sup>, 3PN, 2WC, 3 tầng):** Giá ước tính = `28.543 tỷ` [Khoảng tin cậy  $\pm 15\%$ : 24.262 tỷ – 32.824 tỷ] 2. **Biệt thự TP.HCM (250m<sup>2</sup>, 5PN, 4WC, 2 tầng):** Giá ước tính = `78.215 tỷ` [Khoảng tin cậy  $\pm 15\%$ : 66.483 tỷ – 89.947 tỷ] 3. **Chung cư Đà Nẵng (65m<sup>2</sup>, 2PN, 1WC, 1 tầng):** Giá ước tính = `7.412 tỷ` [Khoảng tin cậy  $\pm 15\%$ : 6.300 tỷ – 8.524 tỷ]

---

## PHẦN IV: TRIỂN KHAI WEB / MOBILE (IN-BROWSER ML INFERENCE)

### 1. Thuật toán In-Browser ML Engine (Pure JavaScript)

Hệ thống nén mô hình sang `model.json` và thực thi inference trực tiếp trên trình duyệt web / mobile web client mà không cần server backend: - **Bài 1 (Chẩn đoán bệnh):** Random Forest 50 cây (`166.8 KB`), duyệt cây nhị phân trong  $< 1\text{ ms}$ . - **Bài 2 (Giá nhà Việt Nam):** Gradient Boosting 80 cây (`113.9 KB`), tích lũy đầu ra trong  $< 2\text{ ms}$ .

### 2. Tính năng Lời khuyên Y tế & Đề xuất Cá nhân hóa

- Phân tích động Glucose, BMI, DPF, Tuổi để tự động sinh ra các thẻ khuyến nghị lâm sàng (Cảnh báo khám khẩn cấp, chế độ dinh dưỡng Low GI, lộ trình giảm cân tăng nhạy Insulin, lịch tầm soát di truyền).

### 3. GitHub Repositories & Deploy Vercel (1-Click)

Cả 2 dự án được đẩy lên GitHub và sẵn sàng deploy Vercel Serverless: - **Bài 1 Repos:** <https://github.com/trieu123x/disease-prediction> - **Bài 2 Repos:** <https://github.com/trieu123x/housing-price-prediction>

---

## PHẦN V: REFLECTION VÀ KẾT LUẬN

### 1. Trả lời 8 Câu hỏi Reflection

1. **Khái niệm Hệ thống thông minh:** Được thể hiện qua khả năng chuyển đổi dữ liệu môi trường thành Vector  $x \in \mathbb{R}^d$ , học quy luật từ dữ liệu mẫu và suy luận kết quả cho đối tượng mới. 2. **Vai trò của Biểu diễn dữ liệu:** Dữ liệu được làm sạch, mã hóa chuẩn xác là điều kiện tiên quyết quyết định chất lượng dự đoán. 3. **Traditional ML vs Deep Learning:** Dữ liệu bảng dưới 2,000 mẫu rất phù hợp với Random Forest & Gradient Boosting về độ chính xác, tốc độ và tính minh bạch. 4. **Feature Scaling:** Cần thiết cho k-NN, SVM và Logistic Regression để tránh các đặc trưng có biên độ lớn áp đảo khoảng cách. 5. **Phân loại vs Hồi quy:** Phân loại cho ra kết quả nhãn rời rạc;

Hồi quy cho ra giá trị liên tục. 6. **Giá trị của Baseline Model:** Cho biết mốc hiệu năng tối thiểu và chứng minh mô hình thực sự tiếp thu tri thức từ dữ liệu ( $R^2$  từ 0.00  $\rightarrow$  0.87). 7. **Triển khai Web / Mobile:** Mô hình nén nhẹ dạng JSON giúp thực thi client-side siêu nhanh trên mọi thiết bị di động. 8. **Hướng phát triển:** Thu thập thêm dữ liệu thực tế và nâng cấp mô hình Deep Learning trong các Assignment tiếp theo.

## 2. Kết luận

---

Báo cáo đã hoàn thành đầy đủ toàn bộ yêu cầu của **Assignment 01 (Bài 1)** và **Assignment 02 (Bài 2)** với lời giải chi tiết, công thức toán học, bảng so sánh và biểu đồ trực quan sắc nét cùng phần giải thích cặn kẽ chuyên sâu.